

RELATÓRIO COMPLETO — Reprodução e Análise Crítica do Paper

1. Introdução

Este trabalho teve como objetivo reproduzir os resultados do artigo:

"XGBoost-Based Anomaly Detection Framework for SOME/IP in In-Vehicle Networks"

O foco principal foi:

- reproduzir fielmente o pipeline do artigo
 - validar as métricas reportadas
 - analisar o impacto do CTGAN
 - avaliar a aplicabilidade real do modelo para IDS automotivo
-

2. Dataset

2.1 Dimensão

O dataset contém aproximadamente:

- **14.23 milhões de mensagens SOME/IP**

Divisão:

Conjunto	Amostras
Treino	7.116.674
Teste	7.116.673

2.2 Distribuição de Classes

Classe	Treino	Teste	%
Normal	6.285.515	6.285.514	88.32%
Ataque	831.159	831.159	11.68%

📌 Dataset altamente desbalanceado (cenário realista)

3. Engenharia de Features

Foram utilizadas **12 features comportamentais**, conforme o paper:

- intervalo temporal entre pacotes
- entropia do payload
- likelihood do payload
- variação de payload (Hamming distance)
- variação de tamanho de pacotes

📌 Importante:

- Features são independentes de header → evita overfitting
 - Capturam comportamento, não identidade
-

4. Pré-processamento

4.1 Normalização

Foi aplicada:

Min-Max Scaling

✓ Essencial para:

- estabilidade do XGBoost
 - funcionamento correto do CTGAN
-

4.2 Split adicional (validação)

Pipeline final:

```
Treino → Validação → Teste
```

- ✓ Threshold NÃO foi escolhido no teste
- ✓ Evita overfitting

5. Modelo

5.1 XGBoost

Parâmetros (idênticos ao paper):

```
n_estimators = 1000  
learning_rate = 0.05  
max_depth = 6  
subsample = 0.8  
colsample_bytree = 0.8
```

5.2 CTGAN

Configuração:

```
embedding_dim = 128  
hidden_layers = [256, 256]  
batch_size = 500  
epochs = 100  
pac = 10
```

Estratégia:

```
Treinar apenas com ataques  
Gerar amostras até balancear dataset
```

6. Experimentos

Foram avaliados:

6.1 Baseline (sem CTGAN)

6.2 CTGAN + XGBoost

Em dois cenários:

Cenário	Descrição
A	Desbalanceado (realista)
B	Balanceado (controlado)

7. Resultados

7.1 Métricas Globais (comparação com paper)

Métrica	Paper	Obtido
PR-AUC	0.93	0.9310
ROC-AUC	0.99	0.9873
F1 (weighted)	0.97	0.9660
Accuracy	~0.97	0.9681

 Reprodução bem-sucedida

7.2 Métricas Reais (classe ataque)

Métrica	Valor
Precision	0.9867
Recall	0.7367
F1	0.8436

 Problema crítico:

~26% dos ataques não são detectados

7.3 Cenário Recall ≈ 0.97

Modelo	Precision	Recall	FP
Baseline	0.5926	0.9703	554.346
CTGAN	0.5918	0.9706	556.335

📌 Resultado:

CTGAN não melhora o desempenho

7.4 Cenário Balanceado

Modelo	F1	Precision	Recall
Baseline	0.9429	0.9169	0.9703
CTGAN	0.9429	0.9167	0.9706

📌 Mesmo comportamento

8. Análise Crítica

8.1 Sobre o F1 do paper

O paper reporta:

$F1 \approx 0.97$

Mas foi identificado que:

$F1 = \text{weighted average}$

📌 Problema:

- dominado pela classe normal (88%)
- mascara baixa detecção de ataques

8.2 Sobre o CTGAN

Resultado observado:

CTGAN $\approx$ baseline

Possíveis explicações:

1. Features já são altamente discriminativas
2. Dataset já contém boa representação de ataques
3. CTGAN não adiciona informação relevante

8.3 Sobre AUC

PR-AUC $\approx$ 0.93
ROC-AUC $\approx$ 0.99

- ✓ Modelo já separa bem classes
- ✓ CTGAN não melhora separação

9. Pontos de Atenção

● 1. Métricas enganosas

- Weighted F1 pode ocultar falhas críticas
- Accuracy não é adequada para IDS

● 2. Recall de ataque

Recall $\approx$ 0.73

👉 Inaceitável para segurança

● 3. Trade-off operacional

Para recall alto:

FP explode ($\approx 500k+$)

● 4. CTGAN

- custo computacional alto
- benefício nulo neste cenário

10. Conclusões

✓ Reprodução

- Pipeline fiel ao paper
- Resultados equivalentes
- Curvas reproduzidas

✓ Descoberta principal

CTGAN não traz ganho significativo neste dataset

✓ Insight crítico

F1 alto não significa bom IDS

✓ Avaliação correta

Para IDS, deve-se priorizar:

- recall de ataque

- falsos negativos
- falsos positivos